

INSTITUTO FEDERAL DO ESPÍRITO SANTO
CURSO DE ENGENHARIA DE CONTROLE E AUTOMAÇÃO

FILIPPE VIANA CANISKY

**DETECÇÃO E CLASSIFICAÇÃO DE ARRITMIAS CARDÍACAS A PARTIR DE
SINAIS DE ELETROCARDIOGRAMAS UTILIZANDO REDES NEURAIS**

Serra
2026

FILIPPE VIANA CANISKY

**DETECÇÃO E CLASSIFICAÇÃO DE ARRITMIAS CARDÍACAS A PARTIR DE
SINAIS DE ELETROCARDIOGRAMAS UTILIZANDO REDES NEURAIS**

Trabalho de Conclusão de Curso apresentado à
Coordenadoria do Curso de Engenharia de Controle e
Automação do Instituto Federal de Educação, Ciência
e Tecnologia do Espírito Santo, como requisito parcial
para a obtenção do título de Engenheiro de Controle e
Automação.

Orientador: Prof. Dr. Flávio Garcia Pereira

Serra

2026

AGRADECIMENTOS

À minha família, pelo amor, apoio incondicional e compreensão em todos os momentos desta caminhada acadêmica.

Aos amigos, pela parceria, pelas conversas e pelo incentivo nos momentos mais difíceis da graduação.

Ao meu orientador, Prof. Dr. Flávio Garcia Pereira, pela orientação, paciência, disponibilidade e pelos valiosos ensinamentos compartilhados ao longo do desenvolvimento deste trabalho.

Aos professores do curso de Engenharia de Controle e Automação, pelos conhecimentos transmitidos e pela contribuição à minha formação profissional e pessoal.

RESUMO

Este trabalho aborda a detecção e classificação de arritmias cardíacas em sinais de eletrocardiograma (ECG), utilizando técnicas de inteligência artificial para apoiar o diagnóstico clínico e o monitoramento automatizado. O objetivo principal é desenvolver e comparar modelos de redes neurais convolucionais unidimensionais (CNN1D) e bidimensionais (CNN2D) aplicados à classificação de batimentos cardíacos na base de dados MIT-BIH Arrhythmia Database, considerando cinco classes: batimentos normais, três tipos de arritmias e uma classe de batimentos não classificados. O processamento dos sinais envolveu etapas de pré-processamento, segmentação dos batimentos e organização dos conjuntos de treino e teste, seguido do projeto e ajuste das arquiteturas convolucionais. O desempenho dos modelos foi avaliado por meio das métricas acurácia, sensibilidade, especificidade, precisão e F1-score. A CNN1D obteve média geral de acurácia de 97,44%, sensibilidade de 93,60%, especificidade de 98,40%, precisão de 93,66% e F1-score de 93,61%, enquanto a CNN2D alcançou acurácia média de 97,36%, sensibilidade de 93,40%, especificidade de 98,35%, precisão de 93,65% e F1-score de 93,41%. Esses resultados indicam um desempenho equivalente entre as abordagens, demonstrando o potencial de ambas as arquiteturas propostas para aplicação em sistemas de engenharia voltados ao monitoramento cardíaco e ao suporte à decisão em ambiente clínico.

Palavras-chave: Arritmias. Eletrocardiograma. CNN1D. CNN2D. MIT-BIH.

ABSTRACT

This work addresses the detection and classification of cardiac arrhythmias in electrocardiogram (ECG) signals, using artificial intelligence techniques to support clinical diagnosis and automated monitoring. The main objective is to develop and compare one-dimensional (CNN1D) and two-dimensional (CNN2D) convolutional neural network models applied to heartbeat classification on the MIT-BIH Arrhythmia Database, considering five classes: normal beats, three types of arrhythmias, and a class of unclassified beats. Signal processing involved stages of preprocessing, heartbeat segmentation, and organization of training and testing sets, followed by the design and tuning of the convolutional architectures. The models' performance was evaluated using accuracy, sensitivity, specificity, precision, and F1-score metrics. The CNN1D obtained an overall average accuracy of 97,44%, sensitivity of 93,60%, specificity of 98,40%, precision of 93,66%, and F1-score of 93,61%, while the CNN2D achieved an average accuracy of 97,36%, sensitivity of 93,40%, specificity of 98,35%, precision of 93,65%, and F1-score of 93,41%. These results indicate equivalent performance between the approaches, demonstrating the potential of both proposed architectures for application in engineering systems aimed at cardiac monitoring and decision support in a clinical environment.

Keywords: Arrhythmias. Electrocardiogram. CNN1D. CNN2D. MIT-BIH.

LISTA DE ILUSTRAÇÕES

Figura 1 – Eletrocardiograma normal	14
Figura 2 – Exemplo de batimento da classe N	29
Figura 3 – Exemplo de uma transformação	33
Figura 4 – Matriz de confusão da CNN1D	37
Figura 5 – Matriz de confusão da CNN2D	39
Figura 6 – Curvas CNN1D	41
Figura 7 – Curvas CNN2D	41

LISTA DE TABELAS

Tabela 1 – Comparativo entre trabalhos relacionados	24
Tabela 2 – Classes da base de dados do MIT-BIH	26
Tabela 3 – Classificação das classes de ECG segundo o padrão AAMI	26
Tabela 4 – Detalhamento da arquitetura proposta da CNN1D	30
Tabela 5 – Detalhamento da arquitetura proposta da CNN2D	34
Tabela 6 – Métricas de desempenho da CNN1D	38
Tabela 7 – Métricas de desempenho da CNN2D	40

LISTA DE SIGLAS

1D	Unidimensional
2D	Bidimensional
AAMI	Associação para o Avanço da Instrumentação Médica
CNN	Rede Neural Convolucional
CNN1D	Rede neural convolucional unidimensional
CNN2D	Rede neural convolucional bidimensional
ECG	Eletrocardiograma
GAN	Rede Adversária Generativa
GRU	Unidade Recorrente com Portões
FN	Falso Negativo
FP	Falso Positivo
IA	Inteligência Artificial
LSTM	Memória de Longo e Curto Prazo
ReLU	Unidade Linear Retificada
SMOTE	Técnica de sobreamostragem sintética da classe minoritária
STFT	Transformada de Fourier de Curta Duração
TN	Verdadeiro Negativo
TP	Verdadeiro Positivo

SUMÁRIO

1	INTRODUÇÃO	10
1.1	CONTEXTUALIZAÇÃO	10
1.2	JUSTIFICATIVA	11
1.3	OBJETIVOS	12
1.4	ESTRUTURA DO TRABALHO	12
2	FUNDAMENTAÇÃO TEÓRICA	13
2.1	SISTEMA CARDIOVASCULAR E ARRITMIAS CARDÍACAS	13
2.2	ELETROCARDIOGRAMA	13
2.3	INTELIGÊNCIA ARTIFICIAL	14
2.4	REDES NEURAIS CONVOLUCIONAIS	15
2.5	PREPARAÇÃO E REPRESENTAÇÃO DOS DADOS	16
2.6	DIVISÃO DOS DADOS E VALIDAÇÃO	17
2.7	REGULARIZAÇÃO	18
2.8	FUNÇÕES DE PERDA E OTIMIZADORES	19
2.9	MÉTRICAS DE AVALIAÇÃO	20
3	TRABALHOS RELACIONADOS	22
3.1	ABORDAGENS UNIDIMENSIONAIS (1D)	22
3.2	ABORDAGENS BIDIMENSIONAIS (2D)	23
3.3	COMPARAÇÕES	24
4	METODOLOGIA	25
4.1	BASE DE DADOS MIT-BIH	25
4.2	PRÉ-PROCESSAMENTO	27
4.3	ARQUITETURA E TREINAMENTO DA CNN1D	29
4.4	ARQUITETURA E TREINAMENTO DA CNN2D	32
5	RESULTADO E DISCUSSÃO	37
5.1	RESULTADOS DA CNN1D	37
5.2	RESULTADOS DA CNN2D	39
5.3	DISCUSSÃO E COMPARATIVO	40
6	CONCLUSÃO	44
6.1	TRABALHOS FUTUROS	45
	REFERÊNCIAS	46

APÊNDICE A – REPOSITÓRIO	49
---	-----------

1 INTRODUÇÃO

A engenharia aplicada à saúde tem desempenhado um papel fundamental no desenvolvimento de soluções inovadoras para o diagnóstico e monitoramento de doenças cardiovasculares. Dentre essas doenças, as arritmias cardíacas se destacam pela alta prevalência e pelo potencial risco à vida, tornando sua detecção e classificação temas de grande importância clínica e científica. O eletrocardiograma (ECG) permanece como principal exame para análise da atividade elétrica cardíaca, mas desafios relacionados ao grande volume de dados, à subjetividade e à possibilidade de erros na interpretação manual evidenciam a necessidade de métodos automatizados e precisos.

Neste contexto, abordagens baseadas em inteligência artificial, especialmente redes neurais convolucionais, têm sido exploradas com sucesso para a classificação automática de batimentos cardíacos, contribuindo para maior agilidade, acurácia e confiabilidade nos diagnósticos. A presente pesquisa propõe o desenvolvimento e a comparação de modelos CNN1D e CNN2D aplicados à identificação e classificação de arritmias em sinais de ECG, tendo como base de dados o repositório MIT-BIH, referência mundial na área.

Nos subtópicos seguintes serão apresentados a contextualização do tema, a justificativa para a realização deste trabalho, os objetivos estabelecidos e a estrutura adotada para a elaboração deste trabalho.

1.1 CONTEXTUALIZAÇÃO

As arritmias cardíacas constituem um importante problema de saúde pública, associando-se a maior risco de hospitalizações, morbidade e mortalidade cardiovascular. Estudos recentes sobre a epidemiologia dos transtornos de condução e das arritmias cardíacas no Brasil apontam mais de 700 mil internações entre 2014 e 2024, com aumento progressivo dos casos e predominância de atendimentos em caráter de urgência, o que sugere diagnóstico tardio e manejo muitas vezes em situações críticas Brito *et al.* (2025). Análises complementares mostram que esses eventos acometem com maior frequência indivíduos idosos, especialmente acima de 80 anos, sobrecarregando o sistema de saúde e reforçando a necessidade de estratégias de detecção precoce Jesus *et al.* (2024).

A Sociedade Brasileira de Cardiologia destaca o eletrocardiograma de superfície

como exame fundamental para avaliação do ritmo cardíaco, por ser um método não invasivo, amplamente disponível e de baixo custo, essencial para o diagnóstico de arritmias em diversos níveis de atenção à saúde Samesima *et al.* (2022). Porém, a interpretação manual dos registros de ECG pode ser dificultada pela variabilidade dos batimentos, pela presença de artefatos e pelo volume de dados gerados em contextos de monitorização contínua, aumentando o risco de erros.

Nesse cenário, abordagens baseadas em inteligência artificial têm ganhado destaque como ferramentas de apoio ao diagnóstico. Revisões de literatura sobre modelos de deep learning para detecção de arritmias em ECG mostram que redes neurais convolucionais aplicadas à base MIT-BIH Arrhythmia Database atingem acurácia superior a 96% na classificação de batimentos cardíacos, reforçando o potencial dessas técnicas para aprimorar a detecção automática de arritmias Yaqoob *et al.* (2023) e Cretu *et al.* (2023). Dessa forma, a integração entre sinais de ECG e modelos computacionais avançados surge como alternativa promissora para sistemas de monitoramento cardíaco.

1.2 JUSTIFICATIVA

As arritmias cardíacas geram grande impacto clínico e econômico, com elevado número de internações, uso de recursos especializados e risco aumentado de eventos fatais, o que torna necessário aprimorar estratégias de detecção e acompanhamento desses pacientes. A carga de hospitalizações por transtornos de condução e arritmias no Brasil evidencia uma demanda crescente por soluções que auxiliem o diagnóstico de forma mais rápida, padronizada e acessível, especialmente em serviços com alta demanda e oferta limitada de especialistas. O ECG é de fácil acesso e apresenta bons resultados, no entanto, o diagnóstico final ainda depende da avaliação de um especialista. Como esse processo humano pode ser lento e sujeito a falhas, surge como alternativa a utilização de modelos para a detecção e classificação de arritmias cardíacas.

1.3 OBJETIVOS

O objetivo geral do trabalho é desenvolver dois modelos de redes neurais convolucionais (CNN), sendo um modelo de CNN1D e um modelo CNN2D, utilizando a base de dados pública e gratuita do MIT-BIH, visando detectar e classificar os batimentos com arritmia. Para alcançar o objetivo geral é necessário coletar os dados, fazer o pré-processamento, separar de acordo com a classificação dos especialistas, treinar os modelos, verificar as métricas e comparar com resultados já obtidos por outros trabalhos.

1.4 ESTRUTURA DO TRABALHO

Este trabalho está organizado em seis capítulos, dispostos da seguinte forma:

O **Capítulo 2** apresenta a **Fundamentação Teórica**, abordando os conceitos essenciais para a compreensão do estudo, incluindo o funcionamento das CNNs, técnicas de regularização, otimizadores e as métricas de avaliação de desempenho utilizadas para a classificação de arritmias.

O **Capítulo 3** descreve os **Trabalhos Relacionados**, contextualizando a pesquisa no estado da arte atual. Nesta seção, são discutidas abordagens anteriores que utilizaram modelos unidimensionais e bidimensionais, estabelecendo um comparativo direto com a metodologia proposta.

O **Capítulo 4** detalha a **Metodologia** adotada, descrevendo a base de dados MIT-BIH Arrhythmia Database, as etapas de pré-processamento dos sinais (incluindo normalização e segmentação), a geração de espectrogramas via STFT e a arquitetura das redes CNN1D e CNN2D desenvolvidas.

O **Capítulo 5** expõe os **Resultados e Discussão**, apresentando as métricas de desempenho obtidas (acurácia, sensibilidade, especificidade, precisão e F1-Score), as matrizes de confusão e uma análise comparativa entre as abordagens temporal (1D) e espectro-temporal (2D).

Por fim, o **Capítulo 6** apresenta a **Conclusão**, sintetizando as contribuições do trabalho, as limitações encontradas e sugerindo direções para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo são apresentados os conceitos para o desenvolvimento deste trabalho, abrangendo aspectos do sistema cardiovascular, eletrocardiograma, processamento de sinais, inteligência artificial e, em especial, redes neurais convolucionais. A fundamentação teórica fornece a base necessária para compreender as etapas de modelagem e classificação de arritmias cardíacas em registros de ECG.

2.1 SISTEMA CARDIOVASCULAR E ARRITMIAS CARDÍACAS

O sistema cardiovascular é responsável pelo transporte de oxigênio, nutrientes e substâncias essenciais para o funcionamento do organismo, além de remover metabólitos através da circulação sanguínea. O coração atua como uma bomba eletromecânica, cujo funcionamento depende da geração e condução de impulsos elétricos iniciados no nó sinoatrial e propagados por estruturas especializadas do miocárdio Guyton e Hall (2017).


Em condições normais, a condução elétrica ocorre de forma organizada, resultando em um ritmo cardíaco regular, denominado ritmo sinusal. Alterações nesse processo caracterizam as arritmias cardíacas, que são distúrbios na formação ou na condução do impulso elétrico, podendo gerar batimentos rápidos, lentos ou irregulares. Essas alterações podem ter origem atrial, ventricular ou nodal, e variam desde eventos benignos até condições graves, como taquicardia ventricular e fibrilação ventricular, associadas a elevado risco de mortalidade Samesima *et al.* (2022).

2.2 ELETROCARDIOGRAMA

O ECG é um exame não invasivo amplamente utilizado para o monitoramento da atividade elétrica cardíaca, registrando as variações de potencial elétrico geradas durante o ciclo cardíaco. O sinal obtido é representado graficamente por um traçado composto pelas ondas P, QRS e T, bem como pelos intervalos PR e QT, que fornecem informações relevantes sobre o ritmo cardíaco, a condução elétrica e possíveis alterações funcionais e estruturais do coração.

Na figura 1 é possível ver um ECG normal, onde é identificado o complexo QRS, as ondas P e T, os intervalos PR e QT, e o segmento ST. Apesar da grande utilização

Figura 1 – Eletrocardiograma normal



Fonte: Guyton e Hall (2017).

desse exame para diagnósticos, ele é sujeito a ruídos, como interferência da rede elétrica, artefatos musculares, variação da linha de base, variação entre pacientes. O que acaba impactando tanto na análise manual quanto na análise automatizada desse exame.

2.3 INTELIGÊNCIA ARTIFICIAL

A Inteligência Artificial (IA) refere-se ao desenvolvimento e aplicação de algoritmos capazes de identificar e aprender padrões complexos a partir de grandes volumes de dados. Essas técnicas permitem que sistemas computacionais executem tarefas cognitivas, como previsão, classificação e detecção de anomalias, frequentemente alcançando desempenho comparável ou superior ao de especialistas humanos Jiang *et al.* (2017).

Com o avanço da tecnologia, houve um aumento de dispositivos de monitoramento de saúde, notadamente as tecnologias vestíveis (wearables), como relógios inteligentes e pulseiras de atividade. Esses dispositivos possibilitam o registro contínuo e não invasivo de sinais fisiológicos, gerando um volume massivo de dados (Big Data) que ultrapassa a capacidade humana de análise manual em tempo hábil Majumder, Mondal e Deen (2017). Com esse cenário, o desenvolvimento de modelos automatizados robustos, capazes de processar esses sinais para detectar e classificar arritmias cardíacas se faz necessário.

2.4 REDES NEURAIAS CONVOLUCIONAIS

As Redes Neurais Convolucionais (CNNs) representam uma classe especializada de redes neurais artificiais projetadas especificamente para processar dados que possuem uma topologia de grade conhecida, como séries temporais (1D), no caso de sinais de ECG, ou dados de imagem (2D), como espectrogramas Goodfellow, Bengio e Courville (2016).

Diferentemente das redes neurais tradicionais (Perceptrons Multicamadas), onde cada neurônio de uma camada está conectado a todos os neurônios da camada seguinte, as CNNs utilizam a operação matemática de convolução no lugar da multiplicação matricial convencional em pelo menos uma de suas camadas. Essa arquitetura permite que o modelo aprenda filtros (ou kernels) que deslizam sobre os dados de entrada, extraindo características locais e preservando a relação espacial ou temporal dos dados.

Matematicamente, em bibliotecas de aprendizado profundo, a operação de convolução unidimensional discreta aplicada a uma entrada x com um filtro w de tamanho K , pode ser expressa pela seguinte equação:

$$y[i] = \sum_{k=0}^{K-1} x[i+k] \cdot w[k] \quad (2.1)$$

Em que $x[i+k]$ representa o valor do sinal de entrada deslocado, $w[k]$ é o peso do filtro na posição k , e $y[i]$ é o valor resultante na saída. O conjunto desses valores de saída compõe o que é chamado de mapa de características (*feature map*). O mapa de características atua como um detector de padrões, destacando as regiões do sinal original onde as características buscadas pelo filtro, como a inclinação do complexo QRS em um batimento, estão mais presentes.

Após a operação de convolução, os mapas de características são invariavelmente submetidos a uma função de ativação não linear. No presente trabalho, adota-se a função Unidade Linear Retificada (ReLU), definida por:

$$f(x) = \max(0, x) \quad (2.2)$$

A aplicação da ReLU garante que valores negativos resultantes da convolução sejam descartados (zerados), enquanto valores positivos sejam mantidos inalterados.

Essa introdução de não linearidade é estritamente necessária para que a rede consiga mapear funções complexas. Além disso, a ReLU é amplamente adotada por sua eficiência computacional, permitindo o treinamento eficaz de arquiteturas profundas Goodfellow, Bengio e Courville (2016).

Uma arquitetura típica de CNN é composta por uma sequência de três tipos principais de camadas: camadas convolucionais, responsáveis pela extração de característica; Camadas de subamostragem (pooling), que reduzem a dimensionalidade dos mapas de características e conferem invariância a pequenas translações; e camadas totalmente conectadas (dense layers), que realizam a classificação final com base nos atributos extraídos. Essa estrutura hierárquica permite que a rede aprenda desde padrões simples, como bordas e picos, nas primeiras camadas, até conceitos abstratos e complexos nas camadas mais profundas Yamashita *et al.* (2018).

2.5 PREPARAÇÃO E REPRESENTAÇÃO DOS DADOS

O desempenho de algoritmos de aprendizado profundo é fortemente influenciado pela forma como os dados são representados e pré-processados. Em sinais biomédicos como o ECG, os dados brutos frequentemente apresentam variações de amplitude e ruídos de linha de base que podem dificultar a convergência do modelo durante o treinamento. Portanto, técnicas de normalização, como a padronização Z-score ou a normalização Min-Max, são fundamentais para garantir que as características de entrada estejam na mesma escala, facilitando a otimização dos pesos da rede.

Além do pré-processamento no domínio do tempo, a representação adequada do sinal é crucial para explorar diferentes arquiteturas de redes neurais. Enquanto as CNNs 1D operam diretamente sobre a série temporal, as CNNs 2D exigem uma transformação dos dados para o domínio tempo-frequência.

Para converter o sinal unidimensional em uma representação bidimensional (imagem), utiliza-se frequentemente a Transformada de Fourier de Curta Duração (STFT). O ECG é um sinal não estacionário, ou seja, suas frequências variam ao longo do tempo. A Transformada de Fourier clássica captura apenas o conteúdo frequencial global, perdendo a informação de quando essas frequências ocorrem. A STFT supera essa limitação ao dividir o sinal em janelas temporais curtas e aplicar a transformada em cada segmento, gerando um espectrograma que representa a

densidade espectral de energia ao longo do tempo Stankovic, Dakovic e Thayaparan (2013). Essa representação visual permite que a CNN2D identifique padrões complexos, como a variação abrupta de frequência no complexo QRS.

A STFT para um sinal de tempo discreto $x[n]$ é definida pela equação:

$$X(m, \omega) = \sum_{n=-\infty}^{\infty} x[n] \cdot w[n-m] \cdot e^{-j\omega n} \quad (2.3)$$

Em que $w[n]$ representa a função de janela centrada no instante de tempo m , e ω é a frequência angular. O quadrado da magnitude dessa transformada, $|X(m, \omega)|^2$, gera o espectrograma, que representa a densidade espectral de energia ao longo do tempo.

Um aspecto crítico na aplicação da STFT é o compromisso fundamental entre a resolução temporal e a resolução frequencial, governado pelo Princípio da Incerteza de Heisenberg (conhecido em processamento de sinais como limite de Gabor). Esse princípio estabelece que é matematicamente impossível obter precisão arbitrária simultaneamente no tempo e na frequência.

A escolha do tamanho da janela $w[n]$ dita esse balanço: uma janela estreita proporciona excelente localização no tempo (ideal para detectar o instante exato de ocorrência de uma anomalia), mas resulta em baixa resolução em frequência. Inversamente, uma janela larga melhora a precisão frequencial, mas "borra" o sinal no tempo. A definição dos parâmetros da STFT no pré-processamento do ECG é, portanto, um parâmetro de projeto essencial para equilibrar a visualização de variações abruptas de alta frequência (como o complexo QRS) e de oscilações mais lentas (como as ondas P e T).

2.6 DIVISÃO DOS DADOS E VALIDAÇÃO

Um dos desafios centrais no treinamento de redes neurais artificiais é o compromisso entre a otimização e a generalização. A generalização é a capacidade do modelo de performar corretamente em dados inéditos. Quando um modelo se ajusta excessivamente aos dados de treino, capturando ruídos ou flutuações aleatórias em vez dos padrões subjacentes, ocorre o fenômeno conhecido como sobreajuste ou *overfitting*.

Para diminuir esse problema e avaliar a capacidade de generalização de forma imparcial, a literatura estabelece a necessidade de particionar o conjunto de dados

original. Uma das abordagens mais difundidas é o método *Hold-out*. Nesta técnica, os dados são divididos aleatoriamente em subconjuntos distintos e independentes: o conjunto de treinamento, utilizado para o ajuste iterativo dos pesos da rede (aprendizado), e o conjunto de teste, que permanece isolado durante todo o processo de otimização, sendo utilizado exclusivamente para a avaliação final do desempenho do classificador.

2.7 REGULARIZAÇÃO

A regularização consiste em um conjunto de estratégias aplicadas aos algoritmos de aprendizado de máquina com o objetivo de reduzir o erro de generalização, mesmo que isso não reduza (ou até aumente ligeiramente) o erro de treinamento. Essas técnicas são fundamentais para prevenir o *overfitting*, especialmente em redes neurais profundas com grande número de parâmetros Goodfellow, Bengio e Courville (2016).

Uma das técnicas de regularização mais eficazes e amplamente utilizadas é o Dropout. Essa técnica consiste na desativação temporária e aleatória de uma porcentagem de neurônios (e suas conexões) durante a fase de treinamento. Isso força a rede a aprender características mais robustas e distribuídas, impedindo que os neurônios desenvolvam uma co-adaptação complexa onde um depende excessivamente da correção de erros de outros vizinhos. O Dropout aplica uma máscara binária r aos neurônios de uma camada, onde cada elemento de r segue uma distribuição de Bernoulli com probabilidade p :

$$r_j \sim \text{Bernoulli}(p) \quad (2.4)$$

$$\tilde{y} = r \odot y$$

Em que y é o vetor de ativações originais e $\tilde{y}$ é o vetor resultante após o descarte. Essa operação força a rede a aprender características redundantes e distribuídas, impedindo a co-adaptação excessiva entre neurônios. No presente trabalho, utiliza-se uma taxa de $p = 0,5$ nas camadas densas. Esse valor é amplamente adotado na literatura, conforme proposto por Srivastava *et al.* (2014), por apresentar bom desempenho empírico na redução de overfitting.

Do ponto de vista teórico, a variância da distribuição Bernoulli associada ao dropout, dada por $\text{Var}(m) = p(1 - p)$, é maximizada em $p = 0,5$, o que implica maior

aleatoriedade na ativação dos neurônios. No entanto, a escolha dessa taxa também depende do contexto do modelo e dos dados, sendo frequentemente definida com base em validação empírica.

Além do Dropout, utiliza-se a Batch Normalization (Normalização em Lote) para estabilizar o treinamento. Seu objetivo primário é mitigar o problema da mudança de covariável interna (*internal covariate shift*), garantindo que as entradas de cada camada tenham uma distribuição estável. Para um minilote $\mathcal{B} = \{x_1, \dots, x_m\}$, a operação é definida pelas seguintes etapas:

1. Cálculo da média do lote: $\mu_{\mathcal{B}} = \frac{1}{m} \sum_{i=1}^m x_i$ (2.5)

2. Cálculo da variância do lote: $\sigma_{\mathcal{B}}^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_{\mathcal{B}})^2$ (2.6)

3. Normalização: $\hat{x}_i = \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \varepsilon}}$ (2.7)

4. Transformação afim: $y_i = \gamma \hat{x}_i + \beta$ (2.8)

Em que ε é uma constante pequena para estabilidade numérica, e γ (escala) e β (deslocamento) são parâmetros aprendíveis durante o treinamento Ioffe e Szegedy (2015).

2.8 FUNÇÕES DE PERDA E OTIMIZADORES

O treinamento de uma rede neural é um problema de otimização cujo objetivo é minimizar uma função de custo (ou função de perda) que quantifica a disparidade entre as previsões do modelo e os rótulos reais dos dados. Para problemas de classificação multiclasse, onde as saídas representam uma distribuição de probabilidade sobre C classes mutuamente exclusivas, a função de perda mais adequada e amplamente utilizada é a Entropia Cruzada Categórica (Categorical Cross-Entropy) Goodfellow, Bengio e Courville (2016).

Matematicamente, essa função penaliza o modelo de forma logarítmica quando ele atribui uma probabilidade baixa à classe correta. Ao minimizar a entropia cruzada, a rede busca aproximar a distribuição de probabilidade predita (geralmente obtida via função de ativação Softmax na camada de saída) da distribuição real dos dados, maximizando assim a classificação correta Bishop (2006).

Para realizar a minimização dessa função de perda, utilizam-se algoritmos de otimização que ajustam iterativamente os pesos da rede com base nos gradientes

calculados pelo algoritmo de Backpropagation. Embora o Gradiente Descendente Estocástico seja a base desses métodos, algoritmos com taxas de aprendizado adaptativas têm se mostrado mais eficientes em cenários complexos.

O otimizador Adam (Adaptive Moment Estimation), combina as propriedades do AdaGrad, que performa bem com gradientes esparsos, e do RMSProp, que lida com objetivos não estacionários. O algoritmo calcula taxas de aprendizado adaptativas individuais para cada parâmetro a partir das estimativas do primeiro e segundo momentos dos gradientes. O grande diferencial do Adam em relação aos seus predecessores é a inclusão de uma correção de viés (bias correction), que compensa o fato de os momentos serem inicializados como zero. Essa característica torna o Adam mais robusto nas etapas iniciais do treinamento e reduz a necessidade de ajuste fino (tuning) dos hiperparâmetros, garantindo uma convergência estável mesmo em cenários ruidosos Ruder (2016).

2.9 MÉTRICAS DE AVALIAÇÃO

A avaliação quantitativa de modelos de classificação é realizada através da análise da matriz de confusão. Esta matriz confronta as classes reais dos dados com as classes preditas pelo modelo, permitindo a extração de quatro valores fundamentais para cada classe: Verdadeiros Positivos (TP), Verdadeiros Negativos (TN), Falsos Positivos (FP) e Falsos Negativos (FN).

Os componentes fundamentais extraídos da matriz de confusão são definidos da seguinte forma, considerando a classe de interesse (por exemplo, a presença de uma arritmia) como a classe positiva:

- **Verdadeiro Positivo (TP – *True Positive*):** Representa o acerto positivo do classificador. Ocorre quando o modelo prediz corretamente a presença da condição de interesse (a arritmia existe e foi detectada).
- **Verdadeiro Negativo (TN – *True Negative*):** Representa o acerto negativo. Ocorre quando o modelo classifica corretamente a ausência da condição (o batimento é normal e foi classificado como normal).
- **Falso Positivo (FP – *False Positive*):** Também conhecido como **Erro do Tipo I** ou "alarme falso". Ocorre quando o modelo prediz incorretamente a presença

da condição em uma amostra que é, na realidade, negativa (ex: classificar um batimento normal como arritmia).

- **Falso Negativo (FN – *False Negative*):** Também conhecido como **Erro do Tipo II**. Ocorre quando o modelo falha em detectar a condição existente, classificando uma amostra positiva como negativa (ex: classificar uma arritmia perigosa como um batimento normal).

A partir desses valores, calculam-se métricas específicas que expressam diferentes aspectos do desempenho do classificador. A Acurácia é a métrica mais intuitiva, representando a proporção global de acertos do modelo sobre o total de amostras. Embora útil, ela pode ser enganosa em bases de dados desbalanceadas, onde o modelo pode obter alta acurácia apenas classificando todas as amostras na classe majoritária.

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.9)$$

Em contextos médicos, a Sensibilidade (ou Recall) e a Especificidade assumem papel crucial. A Sensibilidade mede a capacidade do modelo de detectar corretamente os casos positivos (presença de arritmia), evitando falsos negativos que poderiam colocar o paciente em risco. Já a Especificidade avalia a capacidade de identificar corretamente os casos negativos (batimentos normais), evitando alarmes falsos.

$$\text{Sensibilidade} = \frac{TP}{TP + FN} \quad ; \quad \text{Especificidade} = \frac{TN}{TN + FP} \quad (2.10)$$

A Precisão avalia a confiabilidade das predições positivas, indicando a proporção de classificações corretas entre todas as amostras que o modelo classificou como positivas. Por fim, o F1-Score é a média harmônica entre a Precisão e a Sensibilidade. Esta métrica é particularmente valiosa para comparar modelos, pois penaliza valores extremos: um F1-Score alto só é obtido se tanto a Precisão quanto a Sensibilidade forem altas, garantindo um equilíbrio entre a detecção de arritmias e a minimização de falsos positivos.

$$\text{Precisão} = \frac{TP}{TP + FP} \quad ; \quad \text{F1-Score} = 2 \cdot \frac{\text{Precisão} \cdot \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}} \quad (2.11)$$

3 TRABALHOS RELACIONADOS

A classificação automática de arritmias cardíacas tem sido amplamente investigada na literatura recente, com destaque para a transição de métodos baseados em extração manual de características para abordagens de aprendizado profundo (*Deep Learning*). Esta seção apresenta estudos relevantes que utilizaram Redes Neurais Convolucionais (CNNs) unidimensionais e bidimensionais.

3.1 ABORDAGENS UNIDIMENSIONAIS (1D)

O trabalho de Kiranyaz, Ince e Gabbouj (2016) é considerado um dos marcos na aplicação de CNNs para classificação de ECG. Os autores propuseram uma arquitetura de CNN1D adaptativa e específica para o paciente, capaz de extrair características diretamente do sinal bruto, sem a necessidade de pré-processamento complexo. O estudo demonstrou que redes 1D podem superar métodos tradicionais em velocidade e eficiência, alcançando acurácia superior a 97% na classificação de batimentos ventriculares e supraventriculares. Este trabalho fundamenta a escolha da CNN1D como uma das abordagens avaliadas nesta pesquisa.

Seguindo essa linha, Kachuee, Fazeli e Sarrafzadeh (2018) propuseram uma representação profunda transferível, utilizando redes residuais aplicadas a sinais de 1D. Esse trabalho propõe reutilizar os aprendizados obtidos do treinamento para detecção de arritmias para detectar infarto do miocárdio. A acurácia média obtida foi de 93.4% para a detecção de arritmias. Um ponto a ser levado em conta é a complexidade da rede utilizada, que teve 13 camadas. Reutilizando o aprendizado, foi obtido uma acurácia de 95.9% para detecção de infarto do miocárdio.

Em uma abordagem mais recente, Khan *et al.* (2023) desenvolveram um modelo de rede neural residual profunda convolucional unidimensional (Deep ResNet 1D) para classificar cinco classes de batimentos cardíacos da AAMI. Utilizando a base de dados PhysioNet MIT-BIH Arrhythmia, os autores lidaram com o desbalanceamento dos dados aplicando a técnica de sobreamostragem sintética da classe minoritária (SMOTE) no conjunto de treinamento. Avaliado através de validação cruzada de 10 dobras (*10-fold cross-validation*), o modelo alcançou uma acurácia média de 98,63%, evidenciando a robustez das redes residuais unidimensionais para a extração direta de características de sinais de ECG.

Um ponto de discussão metodológica central que tem ganhado força na literatura recente sobre a base MIT-BIH é a distinção entre os protocolos intra-paciente e inter-paciente. Trabalhos baseados no protocolo intra-paciente são fundamentais para validar a capacidade inicial de abstração e aprendizado das arquiteturas de rede. No entanto, por permitirem que batimentos de um mesmo indivíduo apareçam simultaneamente no treino, validação e teste, esses estudos tendem a reportar métricas de acurácia mais elevadas em comparação a cenários de aplicação clínica. Buscando focar na capacidade de generalização e visando uma avaliação inter-paciente rigorosa, Zhou *et al.* (2023) propuseram uma abordagem combinando um Perceptron de Múltiplas Camadas (MLP), uma rede de cápsulas ponderadas e um modelo Sequência-para-Sequência aplicados ao sinal 1D. O estudo alcançou uma acurácia de 99,88% e se destacou por lidar de forma eficaz com o desbalanceamento das classes minoritárias da base de dados sem recorrer a técnicas de aumento artificial, como o SMOTE.

3.2 ABORDAGENS BIDIMENSIONAIS (2D)

Com o objetivo de explorar informações no domínio da frequência, diversas pesquisas investigaram a transformação de sinais 1D em representações 2D. Huang *et al.* (2019) desenvolveram um método baseado na Transformada de Fourier de Curta Duração (STFT) para converter batimentos de ECG em espectrogramas, que serviram de entrada para uma CNN 2D. Os autores relataram uma acurácia média de 99,00%, argumentando que a representação tempo-frequência facilita a distinção de arritmias com características espectrais complexas.

Diversificando as técnicas de transformação tempo-frequência, Mohonta, Motin e Kumar (2022) exploraram o uso da Transformada Wavelet Contínua (CWT) para converter os sinais de ECG em escalogramas, que serviram de entrada para uma CNN 2D. Diferentemente da STFT utilizada nesta monografia, a CWT oferece uma resolução multiescala, o que permitiu aos autores atingir uma acurácia global de 99,65%. Apesar do excelente desempenho, a geração de escalogramas via CWT é matematicamente mais custosa que a STFT, o que pode impactar aplicações em tempo real.

Avançando nas metodologias de classificação, arquiteturas como os Transformers têm sido adaptadas para o processamento de imagens bidimensionais no domínio médico. Chen *et al.* (2024) introduziram um método combinando mapas de

tempo-frequência, gerados através da Transformada Wavelet Contínua com a ondaleta complexa de Morlet, com o modelo Swin Transformer. Esta arquitetura hierárquica utiliza um mecanismo de autoatenção baseado em janelas deslocadas para capturar de forma eficiente tanto as características locais quanto as dependências globais de longo alcance presentes nas imagens do ECG. Avaliado na base MIT-BIH, o modelo alcançou uma acurácia de 99,34% no cenário intra-paciente e de 98,37% numa avaliação rigorosa inter-paciente. Este estudo evidencia o grande potencial dos Transformers visuais na superação das limitações de dependência temporal das redes tradicionais.

Buscando unir a capacidade de extração de padrões espaciais das CNNs com a modelagem de dependências temporais, Franklin e Muthukumar (2022) apresentaram uma arquitetura híbrida CNN-LSTM aplicada a representações 2D. O método converte os sinais de ECG em imagens em escala de cinza, as quais são processadas por uma CNN 2D para identificar assinaturas morfológicas, seguidas por camadas LSTM que capturam o contexto sequencial e as dependências de longo prazo dos batimentos. Esta abordagem demonstrou ser eficaz na redução do impacto de ruídos biológicos, permitindo uma classificação robusta. Os resultados obtidos alcançaram uma acurácia de 99,33%, evidenciando o potencial da combinação entre redes convolucionais e recorrentes para a classificação automática de arritmias cardíacas.

3.3 COMPARAÇÕES

A Tabela 1 resume o comparativo entre os métodos do estado da arte.

Tabela 1 – Comparativo entre trabalhos relacionados

Autor/Ano	Entrada	Arquitetura	Classes	Acurácia Média
Kiranyaz et al. (2016)	Sinal 1D	CNN 1D (Rasa)	5	≈ 97,40%
Kachuee et al. (2018)	Sinal 1D	ResNet 1D	5	93,40%
Khan et al. (2023)	Sinal 1D	Deep ResNet 1D	5	98,63%
Zhou et al. (2023)	Sinal 1D	MLP + WCapsule + Seq2Seq	5	99,88%
Huang et al. (2019)	STFT	CNN 2D	5	99,00%
Mohonta et al. (2022)	CWT	CNN2D	5	99,65%
Chen et al. (2024)	CWT	Swin Transformer	5	98,37% (Inter), 99,34% (Intra)
Franklin et al. (2022)	Imagem 2D	CNN-LSTM	5	99,33%

Fonte: Elaborado pelo autor (2026).

4 METODOLOGIA

Este capítulo descreve a metodologia adotada para o desenvolvimento deste trabalho, descrevendo as etapas realizadas desde a obtenção dos dados até a avaliação do desempenho dos modelos propostos. Inicialmente, foi realizada a seleção e organização da MIT-BIH Arrhythmia Database, seguida pelas etapas de pré-processamento dos sinais, depois os dados foram estruturados em conjuntos de treinamento, validação e teste. Na sequência, foram projetadas e implementadas duas arquiteturas de redes neurais convolucionais: uma CNN1D, aplicada diretamente aos sinais temporais de ECG, e uma CNN2D, na qual os batimentos foram representados em formato bidimensional. Ambas as arquiteturas foram treinadas sob a mesma base de dados, sendo os parâmetros de configuração e arquitetura ajustados de forma empírica por meio de experimentações. Essa padronização metodológica possibilitou uma avaliação e comparação direta de desempenho.

4.1 BASE DE DADOS MIT-BIH

A base de dados utilizada neste trabalho foi a MIT-BIH Arrhythmia Database, um dos conjuntos de dados mais empregados em pesquisas relacionadas à detecção e classificação de arritmias cardíacas. Essa base foi desenvolvida pelo MIT em parceria com o Beth Israel Hospital, com o objetivo de fornecer um padrão de referência para avaliação de algoritmos de análise automática de sinais de ECG.

A base do MIT-BIH é composta por 48 registros de ECG, com aproximadamente 30 minutos cada, obtidos a partir de pacientes monitorados em ambiente clínico. Os sinais foram adquiridos com frequência de amostragem de 360 Hz. Cada registro foi anotado por especialistas, indicando a localização temporal dos batimentos e sua respectiva classificação.

Existem 15 tipos de classes no banco que podem ser vista na Tabela 2, como esperado em qualquer base de dados médicos, a quantidade de casos normais é muito superior às demais.

Para reduzir a grande diferença entre as classes foi utilizado o padrão da Association for the Advancement of Medical Instrumentation (AAMI), uma organização que é líder em padrões para tecnologia de saúde. O padrão da AAMI visa agrupar as 15 classes da base do MIT-BIH em 5 grupos com características parecidas, como pode

Tabela 2 – Classes da base de dados do MIT-BIH

Classe	Símbolo
Normal beat	N
Left bundle branch block beat	L
Right bundle branch block beat	R
Atrial premature beat	A
Aberrated atrial premature beat	a
Nodal (junctional) premature beat	J
Supraventricular premature beat	S
Premature ventricular contraction	V
Fusion of ventricular and normal beat	F
Atrial escape beat	e
Nodal (junctional) escape beat	j
Ventricular escape beat	E
Fusion of paced and normal beat	f
Paced beat	/
Unclassifiable beat	Q

Fonte: Elaborado pelo autor (2026).

ser visto na Tabela 3

Tabela 3 – Classificação das classes de ECG segundo o padrão AAMI

Classe AAMI	Tipos de batimentos (MIT-BIH)
Normal (N)	N, L, R, e, j
Supraventricular (S)	A, a, J, S
Ventricular (V)	V, E
Fusion (F)	F
Unknown (Q)	/, f, Q

Fonte: Adaptado de (DAS; ARI, 2014).

4.2 PRÉ-PROCESSAMENTO

A etapa de pré-processamento teve como objetivo preparar os sinais do ECG para utilização no treinamento e avaliação dos modelos de redes neurais convolucionais. Essa etapa é fundamental, uma vez que os sinais brutos apresentam variações de duração, amplitude e distribuição entre as classes, o que pode comprometer o desempenho.

Inicialmente, foram selecionados todos os registros da base MIT-BIH Arrhythmia Database, compostos por sinais de ECG adquiridos com frequência de amostragem de 360 Hz. Para cada registro, foi considerada apenas uma derivação do sinal, correspondente ao canal 0, que representa a derivação MLII. A escolha desta derivação justifica-se por ser o padrão amplamente estabelecido na literatura para a análise da base MIT-BIH, visto que a MLII evidencia com maior clareza a morfologia do complexo QRS. As anotações disponibilizadas pela base foram utilizadas para identificar a posição temporal dos batimentos cardíacos e seus respectivos rótulos.

A partir das anotações, cada batimento foi segmentado em uma janela centrada no pico do complexo QRS. Para essa segmentação, foi definida uma janela inicial maior, com 400 amostras, de modo a permitir deslocamentos temporais durante o processo de aumento de dados. Batimentos localizados próximos às extremidades do sinal, que não permitiam a extração completa da janela, foram descartados.

Em seguida, cada segmento foi normalizado individualmente por meio da normalização min-max, garantindo que os valores do sinal estivessem restritos ao intervalo entre 0 e 1. Essa normalização reduz a influência de variações de amplitude entre diferentes registros e contribui para a estabilidade do treinamento das redes neurais.

Após a segmentação e normalização, os batimentos foram mapeados para as cinco classes definidas pelo padrão AAMI: batimentos normais (N), supraventriculares (S), ventriculares (V), de fusão (F) e desconhecidos (Q). Esse mapeamento foi realizado a partir das classes originais da base MIT-BIH, conforme recomendado na literatura, possibilitando a comparação dos resultados com outros trabalhos da área.

Nesta etapa, foi feita a divisão intra-paciente dos dados. Para evitar o vazamento de dados, a separação dos conjuntos de treinamento, validação e teste ocorreu antes de qualquer técnica de balanceamento. Foram reservadas 200 amostras para validação e 200 para teste em todas as classes, para que a avaliação final não fosse prejudicada

pelo desbalanceamento. Como a classe minoritária (F) possui aproximadamente 800 amostras no total, o uso de 400 amostras para validação e teste consumiu uma parcela significativa dos dados, deixando um volume menor para a fase de treinamento dessa classe.

Classes com quantidade superior a esse valor foram submetidas à subamostragem aleatória. Já as classes com menor quantidade de amostras foram balanceadas por meio de aumento artificial de dados até atingir 1600 amostras por classe. Esse processo foi realizado a partir da replicação aleatória de amostras existentes, seguida da aplicação de transformações estocásticas.


Foram empregadas três técnicas de aumento de dados. A primeira consiste no deslocamento temporal da janela de segmentação, no qual um segmento expandido de 400 amostras (360 amostras centrais mais uma margem de ± 20 amostras) é recortado aleatoriamente, gerando variações na posição do batimento dentro da janela final. A segunda técnica corresponde à adição de ruído gaussiano com média zero e desvio padrão de 0,01, aplicado ao sinal normalizado. A terceira técnica consiste na variação de escala da amplitude do sinal, por meio de um fator multiplicativo aleatório uniformemente distribuído no intervalo de 0,95 a 1,05.

Para cada nova amostra gerada, uma das três técnicas de aumento de dados foi selecionada aleatoriamente com igual probabilidade. O número de amostras geradas por técnica não foi previamente fixado, sendo determinado de forma dinâmica de acordo com a necessidade de balanceamento de cada classe, até atingir o total de 1600 amostras no conjunto de treinamento. Ao final desse processo, os conjuntos gerados foram armazenados em arquivos, a fim de evitar a necessidade de reprocessamento em execuções futuras.

Após o balanceamento, todos os segmentos foram recortados para uma janela final de 360 amostras, correspondente a aproximadamente um segundo de sinal, centrada no batimento cardíaco. Para os conjuntos de validação e teste, não foi aplicado aumento de dados, sendo realizada apenas a extração central da janela, de modo a preservar a fidelidade dos sinais utilizados na avaliação.

Por fim, os conjuntos finais de treinamento e teste foram armazenados em arquivos no formato .npy, permitindo reutilização eficiente dos dados nas etapas subsequentes de treinamento e avaliação dos modelos.

Figura 2 – Exemplo de batimento da classe N



Fonte: Elaborado pelo autor (2026).

4.3 ARQUITETURA E TREINAMENTO DA CNN1D

Nesta etapa foi desenvolvido e treinado um modelo de CNN1D, aplicado diretamente aos sinais temporais de eletrocardiograma previamente segmentados e normalizados. A utilização de CNN1D é adequada para esse tipo de dado, pois permite a extração automática de características locais ao longo do eixo temporal do sinal, como padrões relacionados ao complexo QRS, ondas P e T.

A arquitetura proposta recebeu como entrada segmentos de ECG com 360 amostras, representando um único canal temporal. O modelo foi estruturado de forma sequencial, composto por três blocos convolucionais seguidos por uma etapa de classificação totalmente conectada.

O primeiro bloco convolucional é formado por uma camada Conv1D com 32 filtros e tamanho de kernel igual a 5, utilizando a função de ativação ReLU. Em seguida, foi aplicada a normalização em lote (Batch Normalization), com o objetivo de estabilizar o processo de treinamento e acelerar a convergência do modelo. Posteriormente, uma camada de MaxPooling1D com fator de redução igual a 2 foi utilizada para diminuir a dimensionalidade do sinal e reduzir a complexidade computacional.

O segundo bloco segue estrutura semelhante, contendo uma camada Conv1D com 64 filtros e kernel de tamanho 5, seguida novamente por Batch Normalization e

MaxPooling1D. Esse bloco permite a extração de padrões temporais mais complexos e hierárquicos presentes nos sinais de ECG.

O terceiro bloco convolucional é composto por uma camada Conv1D com 128 filtros e kernel de tamanho 3, também utilizando ativação ReLU. Assim como nos blocos anteriores, foram aplicadas as etapas de normalização em lote e pooling, aprofundando a capacidade de representação do modelo e reduzindo progressivamente a dimensão do sinal.

Após os blocos convolucionais, a saída do modelo foi transformada em um vetor unidimensional por meio da camada Flatten. Em seguida, foi aplicada uma camada de Dropout com taxa de 50%, com o objetivo de reduzir o risco de sobreajuste durante o treinamento. A etapa de classificação é composta por uma camada densa com 100 neurônios e função de ativação ReLU, seguida por uma camada de saída com cinco neurônios e função de ativação Softmax, correspondente às cinco classes definidas pelo padrão AAMI.

Tabela 4 – Detalhamento da arquitetura proposta da CNN1D

Camada	Filtros/Neurônios	Tamanho do Kernel	Saída
Entrada	-	-	(360, 1)
Conv1D 1	32	5	(356, 32)
Batch Norm 1	-	-	(356, 32)
Max Pooling 1	-	2	(178, 32)
Conv1D 2	64	5	(174, 64)
Batch Norm 2	-	-	(174, 64)
Max Pooling 2	-	2	(87, 64)
Conv1D 3	128	3	(85, 128)
Batch Norm 3	-	-	(85, 128)
Max Pooling 3	-	2	(42, 128)
Flatten	-	-	(5376)
Dropout	-	-	(5376)
Densa (FC)	100	-	(100)
Saída (Softmax)	5	-	(5)

Fonte: Elaborado pelo autor (2026).

O modelo foi treinado utilizando o otimizador Adam, com taxa de aprendizado inicial igual a 0,001, e a função de perda categórica, adequada para problemas de classificação multiclasse.

Para aprimorar o processo de treinamento e evitar sobreajuste, foram empregados mecanismos de controle por meio de callbacks. O ajuste dinâmico da taxa de aprendizado foi realizado utilizando o método `ReduceLROnPlateau`, que reduz a taxa de aprendizado quando a função de perda de validação não apresenta melhora após um número definido de épocas. Além disso, foi adotado o critério de parada antecipada (Early Stopping), interrompendo o treinamento quando não há melhora significativa no desempenho de validação, restaurando automaticamente os melhores pesos obtidos. Também foi implementado o salvamento do melhor modelo durante o treinamento, com base no menor valor da perda de validação.

O treinamento foi realizado por até 100 épocas, com tamanho de lote igual a 64 amostras, utilizando os conjuntos de treinamento e validação definidos na etapa de pré-processamento. Ao final do treinamento, o modelo com melhor desempenho foi carregado e utilizado para a avaliação final, permitindo a obtenção das métricas de desempenho e da matriz de confusão para cada classe.

A definição dos hiperparâmetros do modelo, como o número de filtros, tamanhos de kernel, taxa de dropout e taxa de aprendizado, não foi realizada por meio de uma busca sistemática (como grid search ou random search). Esses valores foram escolhidos com base em práticas consolidadas na literatura para aplicações de redes convolucionais unidimensionais em sinais biomédicos, bem como em experimentações preliminares conduzidas neste trabalho.

A progressão do número de filtros (32, 64 e 128) foi adotada com o objetivo de permitir a extração hierárquica de características, partindo de padrões mais simples até representações mais complexas. Os tamanhos de kernel (5 e 3) foram definidos de forma a capturar padrões locais relevantes no sinal de ECG, como variações associadas ao complexo QRS e às ondas P e T, mantendo um equilíbrio entre capacidade de representação e custo computacional.

A taxa de dropout de 50% foi empregada como uma estratégia de regularização, visando reduzir o risco de sobreajuste, especialmente considerando o uso de dados aumentados artificialmente. Já a taxa de aprendizado inicial de 0,001 foi definida com

base na configuração padrão do otimizador Adam, sendo utilizada na literatura por apresentar boa estabilidade durante o treinamento.

Destaca-se que, embora esses valores tenham se mostrado adequados para o problema proposto, a ausência de um processo sistemático de otimização de hiperparâmetros constitui uma limitação deste trabalho, podendo impactar o desempenho final do modelo.

4.4 ARQUITETURA E TREINAMENTO DA CNN2D

Com o objetivo de explorar informações espectro-temporais dos sinais de eletrocardiograma, foi desenvolvido um segundo modelo baseado em CNN2D. Diferentemente da abordagem unidimensional, nessa estratégia os sinais de ECG foram previamente transformados em representações bidimensionais por meio da análise tempo-frequência, permitindo que o modelo explorasse padrões espaciais associados às variações espectrais do sinal.


Inicialmente, cada segmento de ECG contendo 360 amostras foi convertido em uma imagem por meio da Transformada de Fourier de Curta Duração (STFT). Para essa transformação, foi utilizada frequência de amostragem de 360 Hz, tamanho de janela (nperseg) de 64 amostras e sobreposição (noverlap) de 32 amostras, correspondente a 50% de sobreposição entre janelas consecutivas. A implementação foi realizada por meio da função spectrogram da biblioteca SciPy, que utiliza, por padrão, janela do tipo Hamming.

Considerando os parâmetros adotados, o espectrograma gerado apresenta um número reduzido de quadros temporais, da ordem de dez segmentos ao longo do sinal. Posteriormente, a representação obtida foi redimensionada para 32×32 pixels por meio de interpolação bicúbica, com o objetivo de adequar o formato de entrada da CNN2D. Ressalta-se que esse processo de redimensionamento não adiciona novas informações ao sinal original, atuando apenas na suavização e padronização da representação visual utilizada pela rede neural.

A partir da STFT, foi obtido o espectrograma do sinal. Em seguida, foi aplicada uma transformação logarítmica na escala de potência, utilizando $10\log_{10}(S_{xx} + 10^{-10})$, com o objetivo de realçar componentes de baixa intensidade e melhorar o contraste da imagem.

Em seguida, os valores foram normalizados no intervalo $[0,1]$ por meio de normalização min-max. Posteriormente, os espectrogramas foram redimensionados para o formato 32×32 pixels utilizando interpolação bicúbica e organizados como imagens com um único canal ($32 \times 32 \times 1$), utilizadas como entrada da CNN2D. Um exemplo da representação gerada pode ser observado na Figura 3.

Figura 3 – Exemplo de uma transformação



Fonte: Elaborado pelo autor (2026).

O primeiro bloco convolucional é formado por uma camada Conv2D com 32 filtros, kernel de tamanho 3×3 , função de ativação ReLU e preenchimento do tipo same, preservando as dimensões espaciais da imagem. Em seguida, foi aplicada a normalização em lote (Batch Normalization), com o objetivo de estabilizar o processo de treinamento. A redução dimensional foi realizada por meio de uma camada de MaxPooling2D com fator 2×2 .

O segundo bloco convolucional segue estrutura semelhante, contendo uma camada Conv2D com 64 filtros e kernel 3×3 , também utilizando ativação ReLU e padding same. Após a convolução, foram aplicadas novamente as etapas de normalização em lote e MaxPooling2D, permitindo a extração de padrões espaciais mais complexos associados às variações espectrais do ECG.

O terceiro bloco convolucional é composto por uma camada Conv2D com 128 filtros e kernel 3×3 , seguida por Batch Normalization e MaxPooling2D. Esse bloco aprofunda a capacidade de representação do modelo, possibilitando a identificação de características discriminantes mais abstratas entre as classes de batimentos cardíacos.

Após os blocos convolucionais, a saída do modelo foi convertida em um vetor unidimensional por meio da camada Flatten. Em seguida, foi aplicada uma camada de Dropout com taxa de 50%, com o objetivo de reduzir o sobreajuste. O classificador final

é composto por uma camada densa com 100 neurônios e função de ativação ReLU, seguida por uma camada de saída com cinco neurônios e função de ativação Softmax, correspondentes às cinco classes definidas pelo padrão AAMI.

Tabela 5 – Detalhamento da arquitetura proposta da CNN2D

Camada	Filtros/Neurônios	Tamanho do Kernel	Saída
Entrada	-	-	(32, 32, 1)
Conv2D 1	32	3 x 3	(32, 32, 32)
Batch Norm 1	-	-	(32, 32, 32)
Max Pooling 1	-	2 x 2	(16, 16, 32)
Conv2D 2	64	3 x 3	(16, 16, 64)
Batch Norm 2	-	-	(16, 16, 64)
Max Pooling 2	-	2 x 2	(8, 8, 64)
Conv2D 3	128	3 x 3	(8, 8, 128)
Batch Norm 3	-	-	(8, 8, 128)
Max Pooling 3	-	2 x 2	(4, 4, 128)
Flatten	-	-	(2048)
Dropout	-	-	(2048)
Densa (FC)	100	-	(100)
Saída (Softmax)	5	-	(5)

Fonte: Elaborado pelo autor (2026).

O treinamento do modelo foi realizado utilizando o otimizador Adam, com taxa de aprendizado inicial igual a 0,001, e a função de perda categorical cross-entropy, adequada para problemas de classificação multiclasse.

Para melhorar a convergência e evitar sobreajuste, foram empregados mecanismos de controle baseados em callbacks. O método ReduceLROnPlateau foi utilizado para reduzir automaticamente a taxa de aprendizado quando a perda de validação não apresentava melhora após um número definido de épocas. Além disso, foi adotada a técnica de parada antecipada (Early Stopping), interrompendo o treinamento quando não havia ganho significativo no desempenho de validação, restaurando os melhores pesos obtidos.

O treinamento foi realizado por até 200 épocas, com tamanho de lote igual a 64 amostras, utilizando os conjuntos de treinamento e validação previamente definidos. Ao final do processo, o modelo treinado foi utilizado para gerar as previsões no conjunto de teste, possibilitando a construção da matriz de confusão e o cálculo das métricas de desempenho para cada classe.

Embora tenham sido definidos limites máximos distintos de épocas para treinamento das arquiteturas CNN1D (100 épocas) e CNN2D (200 épocas), ambas utilizaram o mecanismo de Early Stopping para interromper automaticamente o treinamento quando não fossem observadas melhorias na função de perda do conjunto de validação. Dessa forma, os valores estabelecidos representam apenas limites superiores, não correspondendo necessariamente ao número efetivo de épocas executadas por cada modelo. A adoção de um limite maior para a CNN2D teve como objetivo acomodar uma possível convergência mais lenta decorrente da representação bidimensional baseada em espectrogramas. Entretanto, a comparação entre os modelos permanece válida, uma vez que o critério efetivo de parada foi determinado pelo desempenho no conjunto de validação e não pelo número máximo de épocas previamente definido.

A definição dos hiperparâmetros do modelo, como número de filtros, tamanho dos kernels, taxa de dropout e taxa de aprendizado, não foi realizada por meio de uma busca sistemática. Esses valores foram definidos com base em práticas consolidadas na literatura para redes convolucionais aplicadas a imagens, bem como em experimentações preliminares conduzidas neste trabalho.

A progressão do número de filtros (32, 64 e 128) foi adotada com o objetivo de permitir a extração hierárquica de características espaciais, partindo de padrões mais simples até representações mais abstratas. O tamanho de kernel 3×3 foi escolhido por ser amplamente utilizado em arquiteturas convolucionais, apresentando bom desempenho na captura de padrões locais em imagens.

A taxa de dropout de 50% foi empregada como estratégia de regularização, visando reduzir o risco de sobreajuste. A taxa de aprendizado inicial de 0,001 foi definida com base na configuração padrão do otimizador Adam, sendo reconhecida por sua estabilidade em diferentes tarefas de aprendizado profundo.

Destaca-se que a ausência de um processo sistemático de otimização de hiperparâmetros constitui uma limitação deste trabalho, podendo impactar o desempenho

final do modelo.

5 RESULTADO E DISCUSSÃO


Este capítulo apresenta os resultados obtidos a partir do treinamento e da avaliação dos modelos de redes neurais convolucionais propostos neste trabalho. São analisados o desempenho da CNN1D e da CNN2D, considerando as métricas de acurácia, sensibilidade, especificidade, precisão e F1-score. Os resultados são apresentados individualmente para cada modelo e, posteriormente, comparados.

5.1 RESULTADOS DA CNN1D

Nesta seção são apresentados os resultados obtidos pela CNN1D, aplicada diretamente aos sinais temporais de ECG.

A matriz de confusão obtida no conjunto de teste pode ser visualizada na Figura 4.

Figura 4 – Matriz de confusão da CNN1D



Fonte: Elaborado pelo autor (2026).

Observa-se que o modelo apresenta bom desempenho geral, com alta concentração de valores na diagonal principal da matriz, indicando boa taxa de acertos entre as classes. No entanto, a análise detalhada dos erros revela padrões relevantes de confusão entre classes específicas.

A classe N (batimentos normais) apresentou alguns casos de confusão com

as classes S, V e F, o que pode ser explicado pela similaridade morfológica entre determinados batimentos, especialmente em situações onde há variações sutis no sinal de ECG. De forma semelhante, a classe V apresentou pequenas confusões com a classe F, indicando que o modelo pode ter dificuldade em distinguir padrões mais complexos ou intermediários entre essas categorias.

Um ponto particularmente relevante é a ocorrência de batimentos da classe F (batimentos de fusão) classificados como pertencentes à classe N. Esse tipo de erro é criticamente importante do ponto de vista clínico, uma vez que um batimento anômalo sendo interpretado como normal pode levar à subestimação de condições cardíacas potencialmente relevantes. Esse resultado sugere que, embora o modelo apresente bom desempenho global, ainda há limitações na capacidade de identificar corretamente padrões menos frequentes ou mais complexos.

Por outro lado, a classe Q apresentou desempenho praticamente perfeito, com altíssima sensibilidade e precisão, indicando que seus padrões são mais facilmente distinguíveis pelo modelo.

Os valores calculados para cada métrica são apresentados na Tabela 6.

Tabela 6 – Métricas de desempenho da CNN1D

Classe	Acurácia	Sensibilidade	Especificidade	Precisão	F1-Score
N	95,90%	92,50%	96,75%	87,68%	90,02%
S	97,50%	93,00%	98,62%	94,42%	93,70%
V	97,60%	93,00%	98,75%	94,90%	93,94%
F	96,50%	90,00%	98,12%	92,31%	91,14%
Q	99,70%	99,50%	99,75%	99,00%	99,25%
MÉDIA	97,44%	93,60%	98,40%	93,66%	93,61%

Fonte: Elaborado pelo autor (2026).

De forma geral, o modelo apresentou bom desempenho, com acurácia média de 97,44% e F1-score médio de 93,61%. No entanto, a sensibilidade da classe F (90%) é inferior às demais, reforçando a dificuldade do modelo em identificar corretamente esse tipo de batimento. Esse comportamento é esperado, dado que essa classe apresenta menor representatividade e maior complexidade morfológica em comparação


às demais.

5.2 RESULTADOS DA CNN2D

Nesta seção são apresentados os resultados obtidos pela CNN2D, utilizando como entrada os espectrogramas gerados a partir da Transformada de Fourier de Curta Duração (STFT).

A matriz de confusão correspondente pode ser vista na Figura 5.

Figura 5 – Matriz de confusão da CNN2D



Fonte: Elaborado pelo autor (2026).

A classe N apresentou confusões principalmente com as classes S, V e F, o que pode estar associado à similaridade entre padrões espectrais de batimentos normais e alguns tipos de arritmias, especialmente quando as variações são sutis no domínio da frequência. A classe S também apresentou confusão relevante com a classe N, indicando dificuldade do modelo em separar completamente essas categorias.

A classe V apresentou bom desempenho geral, com alta taxa de acerto, embora ainda ocorram algumas confusões com a classe F. Esse comportamento sugere que, mesmo no domínio espectral, certos padrões associados a batimentos ventriculares e de fusão permanecem próximos, dificultando sua distinção.

Um ponto crítico observado é novamente a confusão de batimentos da classe F com a classe N. Esse tipo de erro possui relevância clínica significativa, pois representa a classificação de batimentos anômalos como normais, o que pode levar à não detecção de eventos cardíacos importantes. Além disso, observa-se também confusão da classe F com a classe V, reforçando a complexidade na identificação desse tipo de batimento.

Novamente a classe Q apresentou bom desempenho, com altíssima taxa de acerto, indicando que seus padrões espectrais são bem definidos e facilmente separáveis pelo modelo.

Os valores calculados para as métricas de avaliação da CNN2D encontram-se na Tabela 7.

Tabela 7 – Métricas de desempenho da CNN2D

Classe	Acurácia	Sensibilidade	Especificidade	Precisão	F1-Score
N	95,70%	92,50%	96,50%	86,85%	89,59%
S	97,30%	90,00%	99,12%	96,26%	93,02%
V	97,20%	97,50%	97,12%	89,45%	93,30%
F	96,90%	88,00%	99,12%	96,17%	91,91%
Q	99,70%	99,00%	99,88%	99,50%	99,25%
MÉDIA	97,36%	93,40%	98,35%	93,65%	93,41%

Fonte: Elaborado pelo autor (2026).

De maneira geral, o modelo apresentou desempenho elevado, com acurácia média de 97,36% e F1-score médio de 93,41%. Entretanto, observa-se que a sensibilidade da classe F (88%) é inferior às demais, indicando maior dificuldade na identificação correta desse tipo de batimento. Esse resultado reforça a complexidade dessa classe e sugere que, mesmo com a utilização de representações espectro-temporais, ainda há limitações na discriminação de padrões mais sutis e menos representativos.

5.3 DISCUSSÃO E COMPARATIVO


Os resultados obtidos indicam que ambos os modelos propostos apresentaram bom desempenho na tarefa de classificação de batimentos cardíacos, com métricas médias bastante próximas entre si. A CNN1D apresentou desempenho ligeiramente

superior em relação à CNN2D na maioria das métricas globais, especialmente em sensibilidade e F1-score. No entanto, essa diferença não é expressiva o suficiente para afirmar, de forma conclusiva, a superioridade de uma abordagem sobre a outra.

A análise das matrizes de confusão evidencia que ambos os modelos apresentam maior dificuldade na classificação das classes minoritárias, especialmente a classe F (batimentos de fusão). Em ambos os casos, observa-se uma tendência de confusão entre as classes F e N, o que pode ser explicado pela semelhança morfológica entre esses tipos de batimentos no domínio temporal. Esse comportamento é clinicamente relevante, pois a classificação incorreta de batimentos anômalos como normais pode comprometer a confiabilidade de sistemas automatizados de apoio ao diagnóstico.


As curvas de aprendizado dos modelos, apresentadas nas Figuras 6 e 7, permitem uma análise mais aprofundada do comportamento durante o treinamento.

Figura 6 – Curvas CNN1D



Fonte: Elaborado pelo autor (2026).

Figura 7 – Curvas CNN2D



Fonte: Elaborado pelo autor (2026).

No caso da CNN1D, observa-se que a acurácia no conjunto de treinamento

crece rapidamente, aproximando-se de valores próximos a 100%, enquanto a acurácia de validação estabiliza em torno de 94%. De forma semelhante, a função de perda apresenta queda acentuada nas primeiras épocas, seguida por estabilização no conjunto de validação. Esse comportamento indica a presença de um leve sobreajuste, evidenciado pela diferença entre os desempenhos de treino e validação. No entanto, esse efeito é moderado e foi adequadamente controlado pelo uso de técnicas de regularização, como Dropout e Early Stopping, que interrompeu o treinamento por volta da época 14, evitando degradação do desempenho em validação.

Para a CNN2D, observa-se comportamento semelhante, porém com indícios mais pronunciados de sobreajuste. A acurácia no conjunto de treinamento atinge rapidamente valores próximos a 100%, enquanto a acurácia de validação permanece em torno de 92–93%, com maior instabilidade ao longo das épocas. Além disso, a função de perda no conjunto de validação apresenta oscilações mais evidentes após as primeiras épocas, sugerindo maior sensibilidade do modelo a variações nos dados de treinamento.

Comparativamente, os resultados indicam que, embora a CNN2D possua alta capacidade de aprendizado, a CNN1D apresentou melhor equilíbrio entre ajuste aos dados de treinamento e capacidade de generalização. Esse comportamento pode estar relacionado ao fato de que a representação temporal preserva diretamente as características morfológicas do sinal de ECG, enquanto a transformação para domínio espectro-temporal pode introduzir perda de informação ou simplificações decorrentes do redimensionamento das imagens.

De modo geral, as curvas de aprendizado evidenciam que ambos os modelos convergem rapidamente e se beneficiam do uso de mecanismos de regularização, sendo o critério de parada antecipada fundamental para evitar o sobreajuste e garantir melhor desempenho no conjunto de validação.

Quando comparados com trabalhos relacionados da literatura, os resultados obtidos neste estudo apresentam desempenho inferior. Essa diferença pode ser atribuída a diversos fatores. Primeiramente, muitos desses trabalhos utilizam arquiteturas mais profundas ou híbridas, combinando CNNs com outras abordagens, como redes recorrentes ou mecanismos de atenção, o que aumenta a capacidade de extração de características complexas.

Além disso, diferenças no pré-processamento dos sinais podem impactar significativamente o desempenho. Enquanto neste trabalho foram utilizados segmentos de 360 amostras centrados no batimento, outros estudos empregam janelas maiores ou técnicas adicionais de filtragem e remoção de ruído. Outro fator relevante é o protocolo de avaliação: alguns trabalhos utilizam validação cruzada entre pacientes (inter-patient), enquanto outros podem adotar divisões intra-paciente, o que tende a resultar em métricas mais elevadas devido à menor variabilidade entre os dados de treino e teste.

Outro aspecto importante diz respeito à definição dos hiperparâmetros. Neste trabalho, os parâmetros da rede, como número de filtros, tamanho dos kernels, taxa de dropout e taxa de aprendizado, foram definidos com base em práticas comuns da literatura e experimentações preliminares, sem a realização de uma busca sistemática. Essa escolha pode ter limitado o desempenho final dos modelos, uma vez que configurações mais otimizadas poderiam potencialmente produzir melhores resultados.

Adicionalmente, destaca-se que os resultados apresentados são provenientes de uma única execução para cada modelo, utilizando uma semente aleatória fixa (seed 42). Dessa forma, não foi realizada uma análise estatística baseada em múltiplas execuções independentes, o que impede a avaliação da variabilidade dos resultados. Consequentemente, não é possível afirmar com rigor estatístico que as diferenças observadas entre os modelos são significativas, podendo estar dentro da variância natural do processo de treinamento.

Apesar dessas limitações, os resultados obtidos demonstram que tanto a abordagem baseada em sinais temporais (CNN1D) quanto a abordagem espectro-temporal (CNN2D) são capazes de capturar características relevantes dos sinais de ECG, apresentando desempenho competitivo para a tarefa proposta.

6 CONCLUSÃO

O presente trabalho propôs o desenvolvimento e a análise comparativa de duas arquiteturas de Redes Neurais Convolucionais (CNN1D e CNN2D) aplicadas à classificação de arritmias cardíacas, utilizando a base de dados MIT-BIH. Diferentemente de abordagens que focam exclusivamente na otimização de hiperparâmetros, este estudo explorou o impacto da representação dos dados na entrada da rede, contrapondo o uso de sinais brutos no domínio do tempo (1D) à utilização de espectrogramas no domínio da frequência (2D). Essa perspectiva permitiu avaliar não apenas a capacidade de generalização dos modelos, mas também o custo-benefício computacional associado ao pré-processamento.

Analisando os resultados obtidos, pode-se concluir que ambas as estratégias mostraram-se eficazes e cumpriram o objetivo de auxiliar no diagnóstico automatizado, atingindo acurácias superiores a 0.97. Contudo, a CNN1D obteve resultados ligeiramente melhores do que a abordagem bidimensional na média global. Além disso, a arquitetura unidimensional opera diretamente sobre os sinais de ECG no domínio temporal, dispensando a etapa de conversão dos dados para espectrogramas.

Apesar dos resultados satisfatórios, este trabalho apresenta algumas limitações que devem ser consideradas. A definição dos hiperparâmetros das redes foi realizada com base em experimentações preliminares, não sendo conduzida uma busca sistemática que pudesse garantir a obtenção da configuração ótima. Além disso, os resultados apresentados correspondem a uma única execução para cada modelo, não sendo realizada uma análise estatística baseada em múltiplas execuções independentes, o que limita a avaliação da variabilidade dos resultados.

Outro ponto relevante refere-se ao pré-processamento dos dados, no qual foram utilizados segmentos de tamanho fixo e técnicas específicas de aumento de dados, cujas escolhas podem influenciar diretamente o desempenho dos modelos. No caso da abordagem 2D, a conversão dos sinais para espectrogramas envolve parâmetros que também impactam a qualidade da representação. Por fim, destaca-se que a avaliação foi realizada exclusivamente na base MIT-BIH, não sendo investigada a capacidade de generalização dos modelos em outras bases de dados.

6.1 TRABALHOS FUTUROS

Como desdobramento deste estudo e visando o aprimoramento contínuo dos sistemas de classificação de arritmias, são sugeridas as seguintes linhas de investigação para trabalhos futuros:

- **Balanceamento de Dados:** Investigar técnicas avançadas de aumento de dados (*Data Augmentation*), como o uso de Redes Adversariais Generativas (GANs), para gerar amostras sintéticas das classes minoritárias (S e F), visando reduzir o viés do classificador em direção à classe normal.
- **Arquiteturas Híbridas:** Explorar a combinação de camadas convolucionais (CNN) para extração espacial de características com camadas recorrentes (LSTM ou GRU) para captura de dependências temporais de longo prazo, o que pode melhorar a classificação de sequências rítmicas complexas.
- **Generalização:** Avaliar o desempenho dos modelos treinados em outras bases de dados públicas (como a do desafio *PhysioNet/CinC* ou a base da INCART), para verificar a capacidade de generalização dos algoritmos frente a diferentes equipamentos de aquisição e perfis de pacientes.
- **Implementação em Hardware:** Portar o modelo CNN1D para sistemas embarcados, avaliando o consumo energético e o tempo de inferência para aplicações em dispositivos vestíveis (*wearables*).

A intenção é que esta pesquisa contribua para a evolução de diferentes metodologias capazes de classificar arritmias cardíacas com alta precisão e baixo custo. Dessa maneira, tais recursos computacionais poderiam ser efetivamente integrados a dispositivos médicos e vestíveis, fornecendo suporte robusto aos profissionais de saúde na realização de diagnósticos precoces e assertivos.

REFERÊNCIAS

- BISHOP, C. M. **Pattern Recognition and Machine Learning**. New York: Springer, 2006.
- BRITO, P. V. M. B. *et al.* Epidemiologia dos transtornos de condução e arritmias cardíacas no brasil: internações e óbitos entre 2014 e 2024. **Brazilian Journal of Implantology and Health Sciences**, v. 7, p. 1628 – 1640, 2025. ISSN 2674-8169. Disponível em: <<https://bjih.s.emnuvens.com.br/bjih.s/article/view/5209>>. Acesso em: 10 nov. 2025.
- CHEN, S. *et al.* A novel method of swin transformer with time-frequency characteristics for ECG-based arrhythmia detection. **Frontiers in Cardiovascular Medicine**, v. 11, 2024. ISSN 2297-055X. Disponível em: <<https://www.frontiersin.org/journals/cardiovascular-medicine/articles/10.3389/fcvm.2024.1401143>>. Acesso em: 07 mar. 2026.
- CRETU, I. *et al.* Reliable multimodal heartbeat classification using deep neural networks. **Journal of Biomedical Engineering and Biosciences (JBEB)**, v. 10, p. 41–52, 2023. ISSN 2564-4998. Disponível em: <<https://jbep.avestia.com/2023/007.html>>. Acesso em: 16 nov. 2025.
- DAS, M. K.; ARI, S. ECG beats classification using mixture of features. **International scholarly research notices**, v. 2014 178436, 2014. Disponível em: <<https://onlinelibrary.wiley.com/doi/10.1155/2014/178436>>. Acesso em: 15 nov. 2025.
- FRANKLIN, R. G.; MUTHUKUMAR, B. Arrhythmia and disease classification based on deep learning techniques. **Intelligent Automation & Soft Computing**, v. 31, p. 835–851, 2022. ISSN 2326-005X. Disponível em: <<http://www.techscience.com/iasc/v31n2/44530>>. Acesso em: 07 mar. 2026.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.l.]: MIT Press, 2016. [Http://www.deeplearningbook.org](http://www.deeplearningbook.org).
- GUYTON, A. C.; HALL, J. E. **Tratado de Fisiologia Médica**. 13. ed. Rio de Janeiro: Elsevier, 2017.
- HUANG, J. *et al.* ECG arrhythmia classification using stft-based spectrogram and convolutional neural network. **IEEE Access**, v. 7, p. 92871–92880, 2019. Disponível em: <<https://ieeexplore.ieee.org/document/8759878>>. Acesso em: 22 nov. 2025.
- IOFFE, S.; SZEGEDY, C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In: BACH, F.; BLEI, D. (Ed.). **Proceedings of the 32nd International Conference on Machine Learning**. Lille, France: PMLR, 2015. (Proceedings of Machine Learning Research, v. 37), p. 448–456. Disponível em: <<https://proceedings.mlr.press/v37/ioffe15.html>>.
- JESUS, C. S. d. *et al.* Prevalência e quadro hospitalar dos transtornos de condução e arritmias cardíacas: um estudo epidemiológico. **CONTRIBUCIONES A LAS CIENCIAS SOCIALES**, v. 17, p. e12442, 2024. Disponível em: <<https://ojs.revistacontribuciones.com/ojs/index.php/clcs/article/view/12442>>. Acesso em: 15 nov. 2025.

JIANG, F. *et al.* Artificial intelligence in healthcare: past, present and future. **Stroke and vascular neurology**, v. 2, p. 230–243, 2017. Disponível em: <<https://pubmed.ncbi.nlm.nih.gov/29507784/>>. Acesso em: 16 nov. 2025.

KACHUEE, M.; FAZELI, S.; SARRAFZADEH, M. ECG heartbeat classification: A deep transferable representation. **2018 IEEE International Conference on Healthcare Informatics (ICHI)**, p. 443–444, 2018. Disponível em: <<https://ieeexplore.ieee.org/document/8419425>>. Acesso em: 22 nov. 2025.

KHAN, F. *et al.* ECG classification using 1-d convolutional deep residual neural network. **PLoS One**, v. 18, p. 1–22, 2023. Disponível em: <<https://doi.org/10.1371/journal.pone.0284791>>. Acesso em: 07 mar. 2026.

KIRANYAZ, S.; INCE, T.; GABBOUJ, M. Real-time patient-specific ECG classification by 1-d convolutional neural networks. **IEEE Transactions on Biomedical Engineering**, v. 63, p. 664–675, 2016. Disponível em: <<https://ieeexplore.ieee.org/document/7202837>>. Acesso em: 22 nov. 2025.

MAJUMDER, S.; MONDAL, T.; DEEN, M. Wearable sensors for remote health monitoring. **Sensors (Basel)**, v. 17, p. 130, 2017. Disponível em: <<https://pubmed.ncbi.nlm.nih.gov/28085085/>>. Acesso em: 16 dez. 2025.

MOHONTA, S. C.; MOTIN, M. A.; KUMAR, D. K. Electrocardiogram based arrhythmia classification using wavelet transform with deep learning model. **Sensing and Bio-Sensing Research**, v. 37, p. 100502, 2022. ISSN 2214-1804. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2214180422000319>>. Acesso em: 22 nov. 2025.

RUDER, S. An overview of gradient descent optimization algorithms. 2016. Disponível em: <<https://arxiv.org/pdf/1609.04747>>. Acesso em: 16 dez. 2025.

SAMESIMA, N. *et al.* Brazilian society of cardiology guidelines on the analysis and issuance of electrocardiographic reports – 2022. **Arq. Bras. Cardiol.**, v. 119, p. 638–680, 2022. Disponível em: <<https://abccardiol.org/en/article/brazilian-society-of-cardiology-guidelines-on-the-analysis-and-issuance-of-electrocardiographic-reports-2022/>>. Acesso em: 15 nov. 2025.

SRIVASTAVA, N. *et al.* Dropout: A simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, p. 1929–1958, 2014. Disponível em: <<http://jmlr.org/papers/v15/srivastava14a.html>>. Acesso em: 07 mar. 2026.

STANKOVIC, L.; DAKOVIC, M.; THAYAPARAN, T. **Time-frequency signal analysis with applications**. [S.l.]: Artech House, 2013.

YAMASHITA, R. *et al.* Convolutional neural networks: an overview and application in radiology. **Insights into imaging**, v. 9, p. 611–629, 2018. Disponível em: <<https://pubmed.ncbi.nlm.nih.gov/29934920/>>. Acesso em: 16 dez. 2025.

YAQOOB, A. *et al.* Deep learning for ECG arrhythmia detection and classification: an overview of progress for period 2017–2023. **Frontiers in physiology**, v. 14, 2023. Disponível em: <<https://www.frontiersin.org/journals/physiology/articles/10.3389/fphys.2023.1246746/full>>. Acesso em: 16 nov. 2025.

ZHOU, C. *et al.* Inter-patient ECG heartbeat classification for arrhythmia classification: a new approach of multi-layer perceptron with weight capsule and sequence-to-sequence combination. **Frontiers in Physiology**, v. 14, 2023. ISSN 1664-042X. Disponível em: <<https://www.frontiersin.org/journals/physiology/articles/10.3389/fphys.2023.1247587>>. Acesso em: 07 mar. 2026.

APÊNDICE A – REPOSITÓRIO

Todos os códigos e documentação referente ao trabalho podem ser encontrados no link: Link: <https://github.com/FilipeVCanisky/Canisky-TCC>